

令和 7 年度 修士論文



機械読唇の精度向上に向けた自然言語処理 による母音列からの日本語文復元

NLP-based Japanese Sentence Reconstruction from Vowel
Sequences for Improving Visual Speech Recognition

指導教員 酒井 哲也 教授

研究指導名 情報アクセス研究

早稲田大学大学院基幹理工学研究科情報理工・情報通信専攻

学籍番号 5124F084

橋本 和音

提出日 2026 年 1 月 26 日

概要

視覚的音声認識（Visual Speech Recognition; VSR）においては、話者の口唇運動から母音は比較的高精度に認識可能である一方、子音は視覚的に識別困難であり、完全な発話内容の復元には本質的な限界が存在する。本研究はこの非対称性に着目し、日本語の母音列のみを入力として欠落した子音を補完し、音韻的・統語的・意味的に妥当な文を生成する「母音列制約付き子音復元（Vowel-Constrained Consonant Restoration; VCCR）」という新たな生成タスクを定義する。VCCR タスクは、入力母音列に対して対応し得る日本語文が原理的に複数存在するという意味で、解が一意に定まらない不定問題である。本研究ではこの性質を前提とし、元文の完全な復元を目的とするのではなく、厳格な母音列制約を満たしつつ、意味的に妥当な文生成がどの程度可能であるかを計算論的に検証する枠組みを構築した。

具体的には、日本語の音韻構造を考慮した母音列一完全文の並列コーパスを既存テキストから生成し、事前学習済み大規模言語モデル（T5 および GPT-2）を用いて VCCR タスクの実験的検証を行った。評価には、生成文が入力母音列を満たしているかを測る制約遵守率（Constraint Compliance Rate; CCR）に加え、BLEU および BERTScore を併用し、生成結果を多角的に分析した。

実験の結果、母音列という極めて限定的な音韻情報のみが与えられた場合でも、一定割合の生成文が制約を満たしつつ意味的に妥当な日本語文として成立することが確認された。一方で、制約遵守と意味的妥当性は必ずしも一致せず、VCCR タスクに固有の限界も明らかとなった。

本研究は、VCCR タスクを通じて、視覚情報から得られる限定的な音韻情報が言語生成において果たし得る役割を定量的に示すとともに、読唇システムにおける補助的モジュールとしての言語モデル活用の可能性を示唆するものである。

目次

第 1 章	序論	9
1.1	研究背景	9
1.2	研究の目的	10
1.3	本論文の貢献	11
第 2 章	関連研究	13
2.1	関連研究の分析	13
2.1.1	逆問題としてのセム語族における母音復元	13
2.1.2	日本語における VCCR タスクの独自性	14
2.2	日本語の音韻的特性	14
2.2.1	母音体系および撥音の視覚的識別性	14
2.2.2	モーラ構造と音韻配列論的制約	15
第 3 章	VCCR タスクの定義と問題設定	17
3.1	日本語音韻構造の整理	17
3.2	識別可能音韻要素としての母音の拡張（5 母音＋撥音）	18
3.3	VCCR タスクの形式定義	18
3.4	曖昧性の種類	18
3.4.1	語彙的曖昧性	18
3.4.2	単語境界の曖昧性	19
3.4.3	意味・文脈的曖昧性	19
3.5	解の非一意性と不定問題としての性質	19
3.6	VCCR タスクの意義と位置付け	19
第 4 章	提案手法	21
4.1	入力表現：母音列化	21
4.2	学習データの生成方法	21
4.3	モデル構成	22

4.3.1	T5 (Text-to-Text Transfer Transformer)	22
4.3.2	GPT-2 (Decoder-only Transformer)	23
4.4	制約の扱い方	23
第 5 章	実験設定	25
5.1	データセット	25
5.2	学習条件	26
5.3	評価指標	27
5.3.1	制約遵守率 (CCR)	27
5.3.2	BLEU	27
5.3.3	BERTScore	28
5.3.4	指標の併用と解釈	28
5.4	比較条件	29
第 6 章	実験結果と分析	31
6.1	定量評価結果	31
6.1.1	指標分布の比較	31
6.2	モデル間比較	35
6.2.1	高一致生成の出現傾向	35
6.2.2	表層一致度のばらつき	36
6.2.3	散布図に基づく挙動の整理	36
6.2.4	具体例による生成結果の確認	37
第 7 章	考察	39
7.1	結果の解釈	39
7.2	評価指標分布から見た VCCR タスクの特性	39
7.3	モデル構造の違いと生成能力の類似性	40
7.4	VCCR タスクの限界	41
7.5	VSR 応用への示唆	41
7.6	本研究から得られた知見	41
第 8 章	結論と今後の展望	43
8.1	結論	43
8.2	今後の展望	43
8.2.1	入力母音列の不確実性を考慮した拡張	43
8.2.2	限定的な子音情報を取り入れた生成モデル	44
8.2.3	前の文脈情報を活用した文生成	44

8.2.4	生成過程における制約の明示的導入.....	44
8.2.5	VCCR タスクの VSR システムへの統合	44
参考文献		49

第 1 章 序論

1.1 研究背景

音声は人間にとって最も自然かつ高効率なコミュニケーション手段であるが、騒音環境下や聴覚障害を持つ人々との対話においては、音声情報に依存しない代替的・補完的な情報経路が不可欠となる。その代表例が、話者の口唇運動や顔画像から発話内容を推定する「読唇 (Lip-reading)」である [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]。読唇は古くから人間の知覚能力として知られてきた [11, 12] が、近年ではディープラーニングの発展により、動画画像から発話内容を自動的に推定する視覚的音声認識 (Visual Speech Recognition; VSR) として、工学的研究 [2, 13, 14, 6, 15, 16] が盛んに行われている。

VSR は、音声認識が困難な環境における代替手段としてのみならず、音声と視覚を統合したマルチモーダル認識の一要素としても注目されている [6, 7]。しかしながら、視覚情報のみを用いて発話内容を完全に復元することには、音声学的・言語学的観点から本質的な困難が存在する。

この困難の核心は、日本語の音韻体系における「母音と子音の視覚的非対称性」にある。日本語の 5 つの基本母音 (/a, i, u, e, o/) は、調音時の口の開閉度や唇の丸めといった明確な視覚的特徴を伴うため、映像情報からの識別が比較的容易である [8]。一方で、/k/, /s/, /t/ など多くの子音は、舌の位置や口腔内での閉鎖・摩擦といった内部的な調音に依存しており、唇形状のみからの識別が困難である。その結果、複数の子音が同一あるいは類似した口形状として観測される「同形異音 (visemes)」の問題が生じ、VSR における主要な誤認識要因となっている [9, 10, 17]。

このような視覚的制約のため、従来の VSR システムでは、子音の誤認識が全体の認識精度を大きく制限してきた。一方で、言語学的・音声学的観点からは、母音の並び (母音列) が正確に把握できれば、日本語の音韻配列論的制約や語彙・統語的文脈を利用することで、欠落した子音を補完できる可能性が示唆される。特に日本語はモーラ (拍) を基本単位とする言語であり [18, 19]、多くの語が規則的な子音 + 母音 (CV) 構造を持つことから、母音列は単なる不完全な情報ではなく、文生成に対して強い制約を与える情報として機能し得る [18]。

近年の大規模言語モデル (Large Language Models; LLM) は、大量のテキストデータから語彙・統語・意味に関する高度な統計的規則性を獲得しており、文脈に基づく欠落情報の補完 (イ

ンフィリング)において顕著な性能を示している [20]. このことは、母音列という音韻的に不完全な情報を入力とし、欠落した子音を文脈から補完するという課題が、VSR と NLP の両分野を結びつける計算論的問題として位置づけられることを示唆している.

本研究ではこの観点に基づき、VSR システムが動画から高精度に抽出可能な「母音列」を前提情報とし、その母音列のみを情報源として欠落した子音を補完し、完全な日本語文を生成する自然言語処理モデルの構築を試みる. この問題設定は、実用的な読唇システムの性能向上に資するのみならず、「視覚から得られる限定的な音韻情報が、言語理解・生成においてどの程度の制約を与え得るか」という基礎的な問いに対する計算論的検証でもある.

本研究は、このような言語学的制約と近年の大規模言語モデルの文脈推論能力を統合し、「母音列のみを入力として日本語文を生成する」という新たな計算論的タスクを定式化し、その実現可能性を実証的に検証することを目的とする.

1.2 研究の目的

本研究の主たる目的は、日本語の母音列のみを入力情報として、欠落した子音を補完し、音韻的・統語的・意味的に妥当な日本語文を生成する「母音列制約付き子音復元 (Vowel-Constrained Consonant Restoration; VCCR)」モデルを構築し、その実現可能性と限界を明らかにすることである.

本研究では、VCCR を単なる文字列復元問題としてではなく、「動画から抽出可能な音韻的特徴が、言語生成にどの程度の制約を与え得るか」を検証する計算論的枠組みとして位置づける. すなわち、元文の表層的な完全一致を必須条件とはせず、母音列という強い制約を満たしつつ、日本語として自然で意味的に妥当な文を生成できるかを評価対象とする.

具体的には、以下の三点を研究目標とする.

1. 日本語の音韻的・形態的特性に基づき、VCCR タスクを計算論的に定義し、学習用の並列コーパスを自動構築する手法を確立する. 特に、日本語特有の促音(「ッ」)、長音など、母音を伴わない音韻成分を意図的に脱落させた母音列を生成し、それらを文脈から補完させるためのデータ設計指針を示す.
2. Text-to-Text Transfer Transformer (T5) をベースラインモデルとして採用し、日本語の音韻ドメインにおける子音復元の実現可能性を検証する. T5 が事前学習により獲得した文脈推論能力を、日本語の規則的なモーラ構造に適用し、母音列が持つ語彙的・統語的曖昧性をどの程度解消できるかを明らかにする.
3. 生成文が入力母音列をどの程度忠実に満たしているかを評価する指標として「制約遵守率 (Constraint Compliance Rate; CCR)」を導入し、既存の自動評価指標と併用することで、モデルの挙動を多角的に分析する.

なお、本研究で扱う VCCR タスクは、入力として与えられる母音列に対して対応し得る日本

語文が原理的に複数存在するという意味で、解が一意に定まらない不定問題である。したがって、本研究の目的は、元文の完全な復元を達成することではなく、母音列という限定的な音韻情報が与えられた場合に、文脈情報や言語的制約を利用することで、読唇タスクの補助としてどの程度有用な文生成が可能であるかを検証することにある。

1.3 本論文の貢献

本論文の主な貢献は、以下の三点に集約される。

1. 視覚的音声認識の文脈に基づき、日本語を対象とした新たな生成タスク「母音列制約付き子音復元 (VCCR)」を定義し、母音列が日本語文生成に与える制約の性質を計算論的に整理した点である。
2. 日本語事前学習済み大規模言語モデルを用いた実験を通じて、母音列という音韻的に不完全な入力からでも、一定の条件下では意味的に妥当な日本語文が生成可能であることを実証的に示した点である。

第 2 章 関連研究

2.1 関連研究の分析

本研究が取り組む「母音列制約付き子音復元 (Vowel-Constrained Consonant Restoration; VCCR)」タスクは、計算言語学および自然言語処理における「部分情報からのテキスト復元 (Text Restoration from Partial Information)」という広範な研究領域に位置付けられる。この領域には、欠落文字の補完、伏字復元、スペル修正、音声認識誤り訂正、さらには暗号文解読など、多様なタスクが含まれる [20, 21, 22].

これらの研究に共通する本質的課題は、不完全あるいは曖昧な入力情報から、文脈および言語的制約を利用してもっともらしい完全なテキストを推定する点にある [20, 21, 23, 24]. 本研究は、この枠組みを音韻レベルにまで拡張し、特に日本語における母音列という極端に制約された情報を入力とする点に特徴がある。

2.1.1 逆問題としてのセム語族における母音復元

本研究の実現可能性を強く支持する先行研究として、アラビア語やヘブライ語といったセム語族言語において長年研究されてきた「母音復元 (Vowel Restoration)」の課題が挙げられる。これらの言語では、文字体系としてアブジャド (abjad) が用いられ、通常の表記では子音のみが記述され、母音は省略される。読み手は、語彙知識および文脈に基づいて適切な母音を補完することが前提とされている。

この課題は計算言語学においても古くから研究されており、統計的手法や確率モデルを用いた多様なアプローチが提案されてきた。例えば、隠れマルコフモデル (Hidden Markov Model; HMM) を用いた研究 [25, 26, 27, 28, 29] では、アラビア語において約 86%、ヘブライ語において約 81% という高い精度で母音パターンの復元に成功したことが報告されている [25].

これらの結果は、「子音列のみ」という極めて不完全な入力からであっても、言語的制約と文脈情報を活用することで音韻情報の補完が可能であることを示している。重要なのは、この母音復元問題が、観測された子音列から欠落した母音を推定する「逆問題」として定式化されている点である。この視点は、本研究が扱う VCCR タスクにおいても共通しており、音韻的に欠落した情報を文脈から推定するという問題構造を共有している。

2.1.2 日本語における VCCR タスクの独自性

一方で、本研究が扱う VCCR タスクは、セム語族における母音復元とは質的に異なる課題である。その最大の理由は、日本語における子音と母音の機能的役割の違いにある [18, 19].

セム語族言語では、語の意味の中核は子音の並び（語根）によって担われ、母音は時制や態、品詞といった文法的情報を付加する役割を持つ。これに対し、日本語では、子音と母音が結合した「モーラ」によって初めて語彙的単位が形成されるため、母音のみ、あるいは子音のみでは意味を担うことができない。

表 2.1 言語特性と復元タスクの比較

言語	復元の対象	推測の性質
セム語族	母音	形態論的: 子音が意味を担い、母音が時制・文法を担う。
日本語	子音	語彙・意味論的: 子音と母音が結合したモーラによって意味が生じる。

したがって、日本語における VCCR タスクは、単なる文法情報の補完ではなく、語彙および意味内容の復元に直接関わる点で、より困難かつ挑戦的な課題である。この違いは、本研究において高精度な完全復元が必ずしも期待できない一方で、日本語の音韻構造と文脈推論能力を検証する上で極めて興味深い対象であることを意味している。

2.2 日本語の音韻的特性

2.2.1 母音体系および撥音の視覚的識別性

日本語の音韻体系は、 $\{A, I, U, E, O\}$ の 5 つの基本母音から構成される比較的単純な体系を持つ。この 5 母音体系は、調音時における口の開閉度、舌の高さ、唇の丸みといったパラメータが明確に異なるため、音声学的にも安定した区別が可能である [18].

視覚的音声認識（Visual Speech Recognition; VSR）の文脈においては、これらの母音が唇形状や口の開閉として明確に可視化される点が重要である。先行研究においても、母音は子音に比べて視覚的認識精度が高いことが報告されており、動画情報から安定して抽出可能な音韻特徴として位置付けられている [1, 8, 7, 17].

さらに日本語特有の音韻要素として、母音を伴わない撥音「ん $\{N\}$ 」が挙げられる。撥音は、口腔内での完全な閉鎖を伴わず、鼻腔への共鳴を特徴とする音であり、視覚的には母音とは異なる上に、多くの子音と比較して比較的一貫した口形・顎位置として観測される。日本語機械読唇の研究では、母音 5 種に撥音を加えた 6 クラス $\{A, I, U, E, O, N\}$ が、他の子音クラスと比較して有意に高い分類精度で識別可能であることが示されている [30].

一方で、破裂音や摩擦音など多くの子音は、調音点が口腔内部に位置するため、外観上の差

異が小さく、視覚情報のみからの安定した識別は困難である。このように、「母音および撥音は比較的高精度に識別可能であるが、多くの子音は視覚的に曖昧である」という機械読唇特有の性質は、本研究が母音列を基点として子音を推定するという問題設定を採用した重要な根拠となっている。

以上を踏まえ、本研究では、VSR システムが高精度に抽出可能な音韻情報として、5 母音に撥音 $\{N\}$ を加えた集合を入力単位とし、これらから構成される系列を VCCR タスクにおける入力表現として用いる。

2.2.2 モーラ構造と音韻配列論的制約

日本語の音韻構造の最大の特徴は、子音と母音が結合した「モーラ」を基本単位とする点にある [18]。日本語の多くの語は「子音+母音 (CV)」という規則的な構造を持ち、音韻配列論的に許容される組み合わせは大きく制限される。

このモーラ構造は、計算言語学的観点から見ると、探索空間を大幅に削減する強力な制約として機能する。すなわち、母音（および撥音）からなる系列が与えられた場合、各位置に挿入可能な子音は、音韻的・語彙的制約によって大きく制限される。阿部の音韻統計研究 [30] によれば、日本語は母音の種類が少ない一方で、出現パターンに強い制約を持つため、不完全な音素情報からでも高い確率で単語を特定できる特性を有する。

本研究はこの統計的性質を利用し、母音および撥音からなる系列を文の音韻的な「骨組み」として捉え、大規模言語モデルが持つ語彙・文脈に関する統計的知識を用いて、欠落した子音情報を補完することで、日本語文の生成を行う。この性質は、母音列+撥音のみから日本語文を生成するという VCCR タスクの理論的基盤を成している。

第3章 VCCR タスクの定義と問題設定

本章では、本研究で取り組む「母音列制約付き子音復元 (Vowel-Constrained Consonant Restoration; VCCR)」タスクについて、その理論的背景、計算論的定義、および問題設定の性質を明確にする。特に、本タスクが解の一意性を持たない不定問題であることを明示し、その上で本研究が目指す検証の射程を整理する。

3.1 日本語音韻構造の整理

日本語の音韻体系は、5つの基本母音 {A, I, U, E, O} と、それらに結合する子音から構成される。多くの日本語語彙は、子音と母音が結合した「モーラ (mora)」を基本単位として形成されており、典型的には「子音+母音 (CV)」という規則的な構造を持つ。

加えて、日本語には、母音を伴わない音韻要素として撥音「ん (N)」が存在する。撥音はモーラの一部として機能しつつ、母音とは異なる音韻的振る舞いを示すが、語彙や文構造において重要な役割を担っている。

このモーラ構造により、日本語では音韻配列論的に許容される音の並びが強く制限される。例えば、任意の子音が任意の位置に自由に出現できるわけではなく、特定の子音と母音（または撥音）の組み合わせのみが語彙として成立する。この制約は、人間の言語処理においては無意識的に利用されているが、計算論的観点から見ると、探索空間を大幅に縮小する強力な制約条件として機能する。

一方で、日本語には撥音のほかにも、促音（「ッ」）や長音など、母音として明示的に表現されない音韻要素が存在する。これらの要素は、母音（および撥音）からなる系列のみを入力とする場合には直接観測されず、文脈や語彙知識に基づく推定が不可欠となる。したがって、日本語の音韻構造は、VCCR タスクにおいて、探索空間を制約する要因であると同時に、解の曖昧性を生み出す要因としても作用する。

3.2 識別可能音韻要素としての母音の拡張（5 母音＋撥音）

前節で述べたように、日本語には母音を伴わない音韻要素として撥音「ん (N)」が存在し、前章で述べた通り、阿部による日本語機械読唇の研究 [30] で他の子音クラスと比較して有意に高い分類精度で識別可能であることが示されている。

そこで本研究では、視覚的音声認識において比較的安定して識別可能な音韻要素として、5 母音に撥音を加えた集合を扱う。本章以降では、特に断りのない限り、「母音」という語は、母音および撥音 $\{A, I, U, E, O, N\}$ を含むものとして、また「母音列」という語も同様に $\{A, I, U, E, O, N\}$ からなる系列を指すものとして用いる。

3.3 VCCR タスクの形式定義

本研究では、VCCR タスクを以下のように定義する。

- **入力 (Input):** 母音＋撥音 $\{A, I, U, E, O, N\}$ からなる母音列 $V = (v_1, v_2, \dots, v_n)$ 。この母音列は、元の日本語文から子音および母音を伴わない音韻要素を除去し、母音のみを抽出することで生成される。
- **出力 (Output):** 音韻的・統語的・意味的に妥当な日本語文 $W = (w_1, w_2, \dots, w_m)$ 。
- **制約条件 (Hard Constraint):** 出力 W を音韻表記に変換した際に得られる母音列が、入力 V と完全に一致しなければならない。

この定義により、VCCR タスクは「制約付き文生成 (Constrained Text Generation)」[23, 24, 31] の一種として位置付けられる。特に本研究では、制約を緩和せず完全一致を要求する点に特徴があり、生成品質と制約遵守の関係を明示的に分析可能である。

3.4 曖昧性の種類

VCCR タスクにおける曖昧性は、主に以下の三つの水準に分類できる。

3.4.1 語彙的曖昧性

同一の母音列に対して、異なる語彙項目が対応する場合に生じる曖昧性である。例えば、母音列が一致していても、子音の違いによって意味の異なる複数の語が成立し得る。

3.4.2 単語境界の曖昧性

母音列のみが与えられた場合、どの位置で単語が区切られるかは一意に定まらない。この曖昧性は、日本語における助詞や活用語尾の存在により、特に顕著となる。

3.4.3 意味・文脈的曖昧性

語彙および単語境界が定まったとしても、文全体としての意味解釈が複数成立する場合がある。この水準の曖昧性は、文脈情報を考慮した高次の意味推論能力を必要とする。

3.5 解の非一意性と不定問題としての性質

VCCR タスクの本質的特徴は、与えられた母音列に対して対応し得る日本語文が原理的に複数存在する点にある。すなわち、本タスクは解が一意に定まらない不定問題である。

例えば、同一の母音列に対して、異なる語彙、異なる単語境界、さらには異なる文構造を持つ複数の日本語文が成立し得る。この曖昧性は、入力情報の欠落による必然的な結果であり、モデルの性能不足によるものではない。

したがって、VCCR タスクにおいて元文の完全な復元を目的とすることは理論的に妥当ではない。むしろ重要なのは、母音列という限定的な音韻情報が与えられた場合に、言語モデルが文脈情報や音韻・語彙制約をどの程度活用し、日本語として自然かつ意味的に妥当な文を生成できるかを評価することである。

3.6 VCCR タスクの意義と位置付け

以上の性質を踏まえると、VCCR タスクは、視覚的音声認識と自然言語処理を橋渡しする計算論的課題として意義を持つ。母音列は動画から比較的高精度に抽出可能である一方、それ単独では意味を一意に定めることができない。この曖昧性をどの程度まで言語モデルが解消できるかを検証することは、読唇システム設計において重要な知見を与える。その意味において、VCCR タスクは完全復元を目的とする課題ではなく、読唇タスクの一部としての貢献可能性を評価するための枠組みとして位置付けられる。

また、VCCR タスクは、音韻的制約を明示的に導入した生成タスクとして、大規模言語モデルの音韻レベルでの一般化能力を評価する新たな枠組みを提供する。本研究はその初期的検証として位置付けられる。

第 4 章 提案手法

本章では、第 3 章で定義した母音列制約付き子音復元 (Vowel-Constrained Consonant Restoration; VCCR) タスクに対して、本研究で採用した具体的な手法を述べる。VCCR タスクは解が一意に定まらない不定問題であるため、本研究では完全復元を目的とせず、厳格な母音列制約を満たしつつ、意味的に妥当な日本語文を生成することを目標とする。

4.1 入力表現：母音列化

本研究では、日本語文をローマ字または音韻表記に変換した上で、母音成分のみを抽出することにより、VCCR タスクにおける入力表現を構築する。具体的には、元文に含まれる子音、および促音（「ッ」）、長音など、明示的な母音を伴わない音韻要素を除去し、 $\{A, I, U, E, O, N\}$ からなる母音列のみを保持する。

この母音列は、視覚的音声認識システムにおいて動画情報から比較的高精度に抽出可能な音韻的特徴を抽象化したものとみなすことができる。したがって、本研究における入力表現は、VSR の出力を理想化した前提の下で設計されている。

4.2 学習データの生成方法

VCCR タスクに対する教師あり学習を行うためには、「母音列」と「完全文」からなる並列コーパスが必要となる。本研究では、既存の日本語テキストコーパスを用い、自動的にこの並列データを構築する手法を採用する。

具体的には、各日本語文に対して音韻変換を施し、母音成分のみを抽出することで入力側データを生成し、元の文を出力側データとして保持する。この手法により、人手によるアノテーションを必要とせず、大規模な学習データを構築することが可能となる。

なお、このデータ生成過程においては、促音などの音韻要素を意図的に脱落するため、モデルは文脈情報に基づいてそれらを推定する必要がある。この点は、VCCR タスクの不定性を反映した設計である。

4.3 モデル構成

本研究では、VCCR タスクに対するベースラインとして、事前学習済みの日本語大規模言語モデルを用いてファインチューニングを行う。具体的には、Encoder–Decoder 型モデルとして Text-to-Text Transfer Transformer (T5) [20]、Decoder-only 型モデルとして GPT-2 [32] 系モデルの、二種類のアーキテクチャを採用する。

これらのモデルは、大規模な日本語テキストに基づく事前学習を通じて、語彙的・統語的・意味的な規則性を獲得しており、文脈に基づく欠落情報の補完能力を有している。そのため、母音列という極端に情報量の少ない入力に対しても、言語的制約を活用した文生成が可能であると期待される。

本研究で用いた具体的な事前学習モデルは以下の通りである。

T5 系モデルとして `megagonlabs/t5-base-japanese-web` ^{*1},

GPT-2 系モデルとして `rinna/japanese-gpt2-medium` [33, 34], ^{*2}

を採用した。両モデルはいずれも、日本語 Web テキストおよび Japanese Wikipedia を含む大規模日本語コーパスを用いて事前学習されている。

4.3.1 T5 (Text-to-Text Transfer Transformer)

T5 (Text-to-Text Transfer Transformer) は、Transformer [35] に基づく Encoder–Decoder 型の事前学習済み言語モデルであり、翻訳・要約・質問応答・文章分類など多様な自然言語処理タスクを、入力と出力の両方をテキストとして表現する「text-to-text」形式に統一して扱うことを特徴とする [20]。例えば、分類タスクであってもラベルをテキストとして出力させ、質問応答では質問文と文脈を入力し答え文を出力させるなど、同一の枠組みによって様々なタスクを学習・推論できる。

T5 の原理は単純に言えば、(1) Encoder が入力系列全体を文脈表現へ変換し、(2) Decoder がその文脈表現を参照しながら出力系列を逐次生成する、という二段階の変換である。Encoder では自己注意 (self-attention) により、入力中の各位置が他の位置と相互参照できるため、入力全体にまたがる依存関係を同時に取り込める。Decoder は自己注意に加えて、Encoder の出力に対する注意 (cross-attention) を用い、生成中の各トークンが入力系列のどの部分に対応するかを参照しつつ、次トークンを確率的に予測して出力を構成する。

本研究では、母音（および撥音）列を入力テキスト、対応する完全文を出力テキストとして与え、VCCR を text-to-text の生成問題として学習する。VCCR では、単語境界の曖昧性や同一母音列に対する語彙候補の多さにより、局所的な手掛かりだけでは復元が困難になる場合が多

^{*1} <https://huggingface.co/megagonlabs/t5-base-japanese-web>

^{*2} <https://huggingface.co/rinna/japanese-gpt2-medium>

い。Encoder–Decoder 構造を持つ T5 は、入力系列全体を一度まとめて符号化した上で生成を行えるため、文全体の文脈を考慮しながら語彙選択や境界決定を行える点で、VCCR タスクにおいて有利に働くと考えられる。

また、T5 は事前学習において、入力文の一部を欠落させて復元する形式の学習を行っており、欠落情報を文脈から補完する能力と親和性が高い [20]。

4.3.2 GPT-2 (Decoder-only Transformer)

GPT-2 は、Transformer [35] に基づく Decoder-only 型の事前学習済み言語モデルであり、自己回帰的 (autoregressive) にトークン列を生成することを特徴とする [32]。事前学習では、大規模な日本語テキストに対して「これまでに与えられたトークン列から次のトークンを予測する」という言語モデル化タスクを通じて、語彙的・統語的・意味的な規則性を獲得する。

GPT-2 の生成原理は、与えられた入力系列を文頭から順に読み込みながら、各時点でそれまでに生成・観測されたトークンのみを条件として、次トークンの確率分布を推定し、逐次的に出力を生成するというものである。この自己回帰的生成では、未来のトークンを参照することはできず、生成は常に左から右へと進行する。そのため、GPT-2 は生成過程において、過去の生成結果に強く依存する構造を持つ。

Decoder-only 構造である GPT-2 は、Encoder–Decoder 型モデルのように入力全体を一度明示的な文脈表現として符号化する機構を持たない。入力系列（本研究では母音列）は、生成開始時にプロンプトとして与えられ、以降の生成では、その入力も含めた「これまでの系列全体」を逐次的に参照しながら、出力が拡張されていく。この構造は、自然な文章生成においては有効である一方、入力全体を俯瞰した最適化や、将来の生成を見越した計画的なトークン選択を行うことは難しい。

VCCR タスクにおいては、母音列という極めて情報量の少ない入力から、語彙選択や単語境界を決定する必要がある。GPT-2 の逐次生成的性質は、初期段階での語彙選択や境界判断の誤りが後続の生成を強く拘束し、文全体の逸脱につながりやすい。一方で、言語モデルとしての強い事前分布により、制約を満たさない場合であっても、流暢で自然な日本語文を生成する傾向があり、制約遵守と自然性の間に顕著なトレードオフが生じることが予想される。

以上より、VCCR タスクは、入力全体を条件として生成を制御する能力と、逐次生成による自然性とのバランスが問われる課題であり、Encoder–Decoder 型と Decoder-only 型という異なるモデル構造の比較は、制約付き文生成におけるモデル挙動を分析する上で本質的である。

4.4 制約の扱い方

VCCR タスクにおける最も重要な要素は、生成文が入力母音列と完全に一致するという厳格な制約条件である。本研究では、この制約を明示的に緩和することは行わず、生成結果に対して事後的に制約遵守を評価する方針を採用する。

すなわち，生成文を音韻表記に変換し，得られた母音列が入力と一致するか否かを判定することで，制約遵守率（Constraint Compliance Rate; CCR）を算出する．この設計により，制約を強制しない場合における大規模言語モデルの内在的な音韻制約処理能力を定量的に評価することが可能となる．

第 5 章 実験設定

本章では、第 4 章で述べた提案手法を評価するために用いた実験設定について述べる。具体的には、使用したデータセット、学習条件、評価指標、および比較条件を整理する。

5.1 データセット

本研究では、日本語テキストコーパスから文単位でデータを抽出し、第 4 章で述べた手法に基づいて「母音列—完全文」からなる並列データを生成した。学習用コーパスとしては、最新の Wikipedia 日本語版のダンプデータ^{*1}を用いた。各文に対して音韻変換を行い、母音および撥音成分のみを抽出した系列を入力、元の日本語文を出力として対応付けた。

Wikipedia 日本語版コーパスから得られた文集合のうち、ランダムに 90% を学習データ（約 216 万文）、9% を検証データ（約 21 万文）、残りの 1% をテストデータ（約 1 万文）として分割した。学習には学習データおよび検証データを用い、評価にはこれらと重複しない文から構成されるテストデータを用いることで、未知の母音列に対する生成性能、すなわちモデルの汎化性能を検証可能な設定とした。

評価においては、性質の異なる 3 種類のデータセットを用い、VCCR タスクにおける生成挙動を多角的に分析した。それぞれのデータセットの位置付けは以下の通りである。

Wikipedia 日本語版データセットのテスト部分

まず、Wikipedia 日本語版データセットのテスト部分（以下、wiki-ja (test)）は、学習に用いたコーパスと同一の文体・ドメインに属するが、文そのものは学習に含まれない。このデータセットは、本タスクにおける成績の上限に近い参照値を与えるリファレンスとして位置付けられる。すなわち、母音列制約下において、モデルが学習時と近い条件でどの程度の生成性能を発揮し得るかを測る基準として用いる。

^{*1} <https://dumps.wikimedia.org/jawiki/latest/jawiki-latest-pages-articles.xml.bz2>

XL-Sum データセット

次に、BBC News 要約データセットである XL-Sum [36] は、本研究における主要な評価対象の一つである。XL-Sum に含まれる文は、学習に用いた Wikipedia 日本語版とは重複しないが、ニュース記事由来の文体や語彙分布が百科事典的文書と比較的近似している。そのため、学習によって獲得された言語知識が未知文に対してどの程度汎化するかを評価する上で適切なデータセットであると考えられる。特に、XL-Sum における成績が wiki-ja (test) の成績にどの程度近づくかは、本タスクにおける汎化性能を判断する上で重要な指標となる。

JSTS データセット

最後に、日本語言語理解ベンチマーク JGLUE [37] に含まれる JSTS データセットを用いた。JSTS は文類似度評価を目的としたデータセットであり、文体・文長・語彙分布の点で、学習に用いた Wikipedia 日本語版コーパスとは大きく異なる性質を持つ。このため、JSTS における生成性能は相対的に低下することが予想される。しかし、この性能低下は本タスクの失敗を意味するものではなく、むしろ特定の文体・ドメインに偏った学習が汎化性能を制限する可能性を示唆するものと解釈できる。JSTS を用いた評価は、より広範な文体・ドメインに対応可能な VCCR モデルを構築する上での課題を明らかにする役割を担う。

以上のように、本研究では、同一ドメインにおける上限参照 (wiki-ja (test))、近接ドメインにおける主要評価 (XL-Sum)、および異なるドメインにおける汎化評価 (JSTS) という異なる役割を持つデータセットを用いることで、VCCR タスクにおける生成性能を段階的かつ体系的に評価した。

5.2 学習条件

モデルの学習および推論には、事前学習済みの日本語大規模言語モデルを用い、母音列を入力、対応する完全文を出力とする教師あり学習によるファインチューニングを行った。本研究で用いた T5 系モデルおよび GPT-2 系モデルは、いずれも同一の並列データ (母音列-完全文対) を用いて学習しており、学習目標自体は共通である。

両モデルの違いは、学習の枠組みそのものではなく、入力情報の与え方および生成過程の形式にある。T5 系モデルでは、Encoder に母音列全体を入力し、Decoder がそれを条件として完全文を生成する Encoder-Decoder 型の教師あり学習を行った。

一方、GPT-2 系モデルでは、Decoder-only 構造を用いるため、母音列をプロンプトとして文頭に与え、それ以降のトークン列を自己回帰的に予測する形式で学習および生成を行った。この場合も、母音列を条件とした完全文生成という点では T5 系モデルと同一の教師あり学習設定であるが、生成は逐次的に行われる点が異なる。

学習時のハイパーパラメータについては、学習率、バッチサイズ、エポック数などを事前に

定めた範囲内で調整し、学習の安定性を重視した設定とした。生成時には、ビームサーチや確率的サンプリングなど、複数のデコード戦略を用いて推論を行った。

5.3 評価指標

本節では、本研究で用いた評価指標について詳細に説明する。母音列制約付き子音復元 (Vowel-Constrained Consonant Restoration; VCCR) タスクでは、生成文が入力として与えられた音韻的制約を満たしているかどうかと、生成文としてどの程度妥当であるかを分けて評価する必要がある。さらに、VCCR タスクは解が一意に定まらない不定問題であるため、単一の評価指標による性能評価は適切ではない。

そのため、本研究では単一の指標に依存せず、制約充足性、表層的一致度、意味的類似度という異なる側面を測る複数の指標を併用し、生成結果を多角的に評価する。

5.3.1 制約遵守率 (CCR)

制約遵守率 (Constraint-Consistency Rate; CCR) は、生成文が入力として与えられた母音列制約を満たしているかを判定する指標である。具体的には、生成文を音韻表記に変換した際の母音の並びが、入力母音列と完全に一致するかを文単位で判定し、一致する場合に 1、一致しない場合に 0 を与える。

CCR は VCCR タスクに固有の評価指標であり、生成文がタスクで課された制約を満たしているかどうかを直接的に評価できる点に特徴がある。一方で、CCR は生成文の自然性や意味の一貫性を保証するものではないため、あくまでも生成品質の必要条件であり、十分条件とはならない。そのため、本研究では CCR を生成品質の必要条件として位置づけ、他の指標と併用して評価を行った。

5.3.2 BLEU

BLEU (Bilingual Evaluation Understudy) [38] は、機械翻訳を中心に広く用いられてきた自動評価指標であり、生成文と参照文の n -gram 一致率に基づいてスコアを算出する。具体的には、生成文中の n -gram が参照文中にどの程度含まれているかを測定し、短すぎる生成を抑制するための brevity penalty を加味して最終スコアを得る。

本研究では、日本語文の表層的な一致を評価するため、単語単位ではなく文字単位で BLEU (BLEU_char) を算出した。これは、日本語において単語境界の定義が曖昧であること、および音韻復元タスクでは文字レベルでの差異が重要となることを考慮したものである。

BLEU_char は、生成文が参照文とどの程度表層的に一致しているかを測る指標として有用である一方、言い換えや語順変更、文末表現の差異に対して敏感であり、意味的に妥当であっても低い値を示す可能性がある。そのため、BLEU_char は生成文の「忠実度」や「再現度」を測

る補助的指標として位置づけ、単独での解釈は避ける必要がある。

5.3.3 BERTScore

BERTScore[39] は、事前学習済み言語モデルによる分散表現（埋め込み）を用いて、生成文と参照文の意味的類似度を評価する指標である。各トークンを文脈依存の埋め込みベクトルに変換し、生成文と参照文のトークン間でコサイン類似度を計算することでスコアを算出する。

BERTScore では、以下の 3 つの値が定義される。

- **Precision**：生成文中の各トークンが、参照文中のいずれかのトークンとどの程度意味的に対応しているかを測る。生成文に含まれる情報のうち、参照文と意味的に一致する割合を反映する。
- **Recall**：参照文中の各トークンが、生成文中でどの程度再現されているかを測る。参照文の意味内容が生成文によってどの程度カバーされているかを反映する。
- **F1**：Precision と Recall の調和平均であり、生成文の過不足を総合的に評価する指標である。

本研究では、BERTScore の代表値として F1 (以下、BERTScore_F1 と呼ぶ) を用いた。これは、生成文が参照文の内容を過度に省略している場合 (Recall が低い) や、不要な情報を付加している場合 (Precision が低い) の双方をバランスよく評価するためである。VCCR タスクでは、入力制約の下で文全体を再構成する必要があるため、生成文の過不足を同時に考慮できる F1 が最も適切であると判断した。

BERTScore は表層的一致に依存せず、意味的に近い文に対して高い値を与えるため、表現の自由度が高い生成タスクにおいて有用である。一方で、一般的・抽象的な表現が過大評価される可能性がある点には留意が必要である。

5.3.4 指標の併用と解釈

本研究では、CCR を制約充足性の指標、BLEU_char を表層的一致度の指標、BERTScore_F1 を意味的類似度の指標として位置づけ、これらを併用して評価を行った。

特に、CCR=1 を満たすサンプルに限定した条件付き評価を併用することで、制約が満たされた場合における生成品質を分離して分析した。このような多面的評価により、単一指標に依存した過度な解釈を避け、VCCR タスクにおける生成挙動をより詳細に分析することを意図している。

5.4 比較条件

本研究では、異なるモデル構成およびデコード戦略に基づく生成結果を比較対象とした。具体的には、T5 系モデルと GPT-2 系モデルの比較を行い、アーキテクチャの違いが VCCR タスクにおける生成挙動に与える影響を分析する。

また、評価においては、制約遵守文のみを対象とした指標算出と、全生成文を対象とした指標算出を区別し、制約条件が評価結果に与える影響を検証可能な設定とした。

第 6 章 実験結果と分析

本章では，第 5 章で述べた実験設定に基づき，VCCR タスクにおいて得られた生成結果を示し，定量評価および分布に基づく分析を行う．ここでは，評価指標の平均値だけでなく，生成結果の分布や指標間の関係に着目することで，モデルの挙動をより詳細に記述する．

なお，本章では結果の記述および観測事実の整理に徹し，それらの解釈や意義については，次章（第 7 章）において考察する．

6.1 定量評価結果

本節では，制約遵守率（CCR），BLEU_char，および BERTScore_F1 を用いた定量的評価結果を示す．

表 6.1 に，各モデルにおける評価結果の概要を示す．ここでは，全生成文を対象とした評価（all）と，母音列制約を満たした生成文のみを対象とした評価（CCR=1）を区別して示している．

表 6.1 各データセット・モデルにおける評価結果の要約

Dataset / Model	N (文の総数)	CCR rate	BLEU_char (all)	BLEU_char (CCR=1)	BERTScore_F1 (all)	BERTScore_F1 (CCR=1)
wiki-ja (test) / T5	9979	0.996	0.519	0.520	0.898	0.899
wiki-ja (test) / GPT-2	9979	0.979	0.542	0.542	0.901	0.902
XL-Sum / T5	1399	0.994	0.467	0.468	0.886	0.886
XL-Sum / GPT-2	1399	0.982	0.492	0.495	0.890	0.891
JSTS / T5	3322	0.958	0.169	0.171	0.806	0.807
JSTS / GPT-2	3322	0.989	0.186	0.187	0.810	0.810

表 6.1 に示すように，モデル間で CCR, BLEU_char, BERTScore_F1 の各指標に差異が観測された．特に，CCR を満たした生成文のみを対象とした場合，BLEU_char および BERTScore_F1 の値が全生成文を対象とした場合と比較して変化する傾向が見られた．

6.1.1 指標分布の比較

図 6.1～図 6.3 に，CCR=1（母音列制約を満たした生成文）のみに限定した BERTScore_F1 の分布を示す．同様に，図 6.4～図 6.6 に BLEU_char の分布を示す．これらの分布を比較することで，平均値のみでは捉えられない生成結果のばらつきや偏りを観察できる．




図 6.1 wiki-ja (test) における BERTScore_F1 の分布図. (a) T5 系モデル, (b) GPT-2 系モデル




図 6.2 XL-Sum における BERTScore_F1 の分布図. (a) T5 系モデル, (b) GPT-2 系モデル






図 6.3 JSTS における BERTScore_F1 の分布図. (a) T5 系モデル, (b) GPT-2 系モデル



(a) model: T5



(b) model: GPT-2

図 6.4 wiki-ja (test) における BLEU_char の分布図. (a) T5 系モデル, (b) GPT-2 系モデル





図 6.5 XL-Sum における BLEU_char の分布図. (a) T5 系モデル, (b) GPT-2 系モデル





図 6.6 JSTS における BLEU_char の分布図. (a) T5 系モデル, (b) GPT-2 系モデル

■BERTScore_F1 分布の全体傾向 いずれのデータセットにおいても、CCR=1 に限定した場合、BERTScore_F1 は高スコア側に集中する傾向が確認できる。すなわち、母音列制約を満たした生成文の多くが、参照文と意味的に近い内容を持つことが、分布の形状として示されている。一方で、分布のピーク位置や広がりにはデータセットごとの差異が見られ、VCCR タスクにおける生成挙動がデータセット性質に依存することが示唆される。

■wiki-ja (test) における BERTScore_F1 分布 wiki-ja ((test) 図 6.1) では、両モデルとも BERTScore_F1 が 0.8 以上の高スコア領域に集中している。特に GPT-2 系モデルでは、BERTScore_F1=1.0 近傍に顕著なスパイクが観測され、参照文と極めて近い生成が一定数存在することが分かる。一方で T5 系モデルは、同様に高スコア域に集中しつつも、分布が比較的滑らかであり、完全一致に近い生成と、意味的に近いが表層表現が異なる生成が混在している様子が観測される。

■XL-Sum における BERTScore_F1 分布 XL-Sum (図 6.2) においても、BERTScore_F1 は高スコア側に集中するが、wiki-ja (test) と比較すると分布の幅がやや広い。これは、要約タスク特有の表現多様性により、参照文と意味的には近いものの、言い回しが異なる生成が多く含まれていることを反映していると考えられる。両モデルの分布形状は概ね類似しているが、GPT-2 系モデルでは高一致側に相対的な重みが残っている。

■JSTS における BERTScore_F1 分布 JSTS (図 6.3) では、BERTScore_F1 のピークが 0.8 付近に位置し、分布の幅も比較的狭い。これは、JSTS が文意味類似を扱うデータセットであり、参照文との完全一致よりも意味的近さが重視される状況に近いことを反映している。その結果、CCR=1 を満たした生成文の多くが一定水準以上の意味類似性を持つ一方で、極端に高い一致度 (1.0 近傍) は相対的に少なくなる傾向が観測される。

■BLEU_char 分布の全体傾向 次に BLEU_char の分布 (図 6.4～図 6.6) を見ると、BERTScore_F1 と比較して分布が広く、低スコア側に長い裾を持つ傾向が顕著である。BLEU_char は表層的な n-gram 一致に基づく指標であるため、語彙選択や言い回しの違いに敏感であり、VCCR のように解が一意に定まらない不定問題においては、意味的に妥当な生成であっても低い値を取る場合が多い。

■wiki-ja (test) および XL-Sum における BLEU_char 分布 wiki-ja ((test) 図 6.4) および XL-Sum (図 6.5) では、BLEU_char は中程度のスコア帯を中心に広く分布している。GPT-2 系モデルでは高スコア側の裾が相対的に厚く、参照文と表層的にも近い生成が一定数存在する一方で、低スコア側も残っており、生成結果の多様性が分布として現れている。T5 系モデルでは、分布が比較的集中しつつも、中程度の一致を中心とした広がりが観測される。

■JSTS における BLEU_char 分布（最も顕著な差異） JSTS（図 6.6）では、BLEU_char の分布が 0.0～0.2 付近に大きく集中し、高スコア側へ長い裾を引く形状となっている。一方で、同じ JSTS における BERTScore_F1 分布（図 6.3）は 0.8 付近に比較的集中しているため、意味的には近いが表層一致は低い生成が多数存在することが分布の組として明確に示されている。この結果は、パラフレーズ性の高い条件において、BLEU が生成品質（意味的妥当性）を過小評価しやすいことを具体的に示している。

■散布図との対応関係 前節で示した BERTScore_F1 と BLEU_char の散布図と併せて解釈すると、wiki-ja (test) および XL-Sum では、BERTScore_F1 の上昇に伴って BLEU_char も上昇する正の相関構造が観測される一方、JSTS では同程度の BERTScore_F1 を持つ生成であっても BLEU_char が低い点が多数存在する。この差異は、各データセットが許容する表現多様性の違いを反映していると考えられる。

以上より、本研究では、特に JSTS のような表現多様性の高い条件においては、BLEU_char を「完全復元度」を直接測る指標としてではなく、参照文近傍への寄り具合を測る補助的指標として解釈する必要があることが確認された。

6.2 モデル間比較

本節では、T5 系モデルと GPT-2 系モデルの生成結果を、指標分布および散布図に基づいて比較する。




図 6.7 wiki-ja (test) における BERTScore_F1–BLEU_char 散布図

6.2.1 高一致生成の出現傾向

BERTScore_F1 の分布（図 6.1, 図 6.2）を見ると、GPT-2 系モデルでは 1.0 近傍に顕著な重みが見られ、参照文と極めて近い生成が一定数存在することが分かる。一方で T5 系モデル




図 6.8 XL-Sum における BERTScore_F1-BLEU_char 散布図




図 6.9 JSTS における BERTScore_F1-BLEU_char 散布図

は、高スコア域に集中しつつも分布が比較的滑らかであり、意味的に近いが表層表現が異なる生成をより多く含む傾向が観測される。

6.2.2 表層一致度のばらつき

BLEU_char の分布（図 6.4, 図 6.5）から、GPT-2 系モデルは高スコア側と低スコア側の両方に裾を持ち、参照文に近い生成から別表現までを幅広く生成している様子が分布として現れている。一方で JSTS（図 6.6）では、両モデルとも BLEU_char が低スコア側へ偏るため、表層一致に基づくモデル比較はデータセット性質を強く受けることが確認できる。

6.2.3 散布図に基づく挙動の整理

BERTScore_F1 と BLEU_char の散布図において、両モデルは正の相関構造を共有するが、点群の広がり方には差が見られる。wiki-ja (test) および XL-Sum では、同程度の BERTScore_F1 に対して BLEU_char のばらつきが大きく、意味的に妥当な別表現が多く含まれる。JSTS では、

意味類似と表層一致の乖離がより顕著に現れ、VCCR タスクにおける評価指標解釈の重要性が分布として明確に示されている。

以上の比較から、同一の母音列制約下においても、モデル構造の違いにより、参照文近傍への収束のしやすさや生成多様性の現れ方が異なることが、分布および散布図の形状として確認された。

6.2.4 具体例による生成結果の確認

分布分析の解釈を具体化するため、XL-Sum における生成結果から、BLEU_char が高・中・低の 3 水準に対応する例を表 6.2 に示す。各例では、入力母音列、参照 (target) カタカナ列、生成 (pred) カタカナ列、および BLEU_char と BERTScore_F1 を併記した。

表 6.2 XL-Sum における VCCR 生成例 (BLEU_char の 3 水準)

入力母音列	target (正解)	pred (生成)	BLEU_char	BERTScore_F1
EENOUOUOEAA22IIIAOUOOEI	ケッセントウヒョウノケッカハ 22 ニチニ ハッピーウノヨテイ	ケッセントウヒョウノケッカハ 22 ニチニ ハッピーウヲヨテイ	0.906	0.974
IAUAIINATAOEIUOUANAUIEIU	リダツハギインタチハコレニツヨクハンパ ツシテイル	イガクシャインカイハコレニツヨクハン パツシテイル	0.602	0.905
OUOUOOUEIENOUAAAIAAUOOIAU	リョウゴクノボウエキセンソウガサラニ アッカスルコトニナル	ドウヨウノコウゲキセンソウハサラニカタ ムコトニナル	0.319	0.856

表 6.2 より、BLEU_char が高い例では参照との表層一致が高く、差分は助詞や表記の揺れに限られる。一方、BLEU_char が中程度の例では、参照文と異なる語彙選択が生じ、表層一致は低下するが、BERTScore_F1 は依然として高く、意味的には近い生成が得られていることが確認できる。さらに BLEU_char が低い例では、参照から大きく異なる表現が生成される一方で、BERTScore_F1 は一定水準を保っており、VCCR タスクが解の一意性を持たない不定問題であること、すなわち「参照文への完全一致」と「意味的妥当性」が必ずしも一致しないことを、具体例として示している。

第 7 章 考察

本章では、第 6 章で示した実験結果に基づき、VCCR タスクにおける生成挙動を解釈し、本研究で得られた知見、課題、および視覚的音声認識（VSR）への示唆について考察する。

7.1 結果の解釈

定量評価の結果から、母音列という極めて限定的な音韻情報のみが与えられた場合でも、一定割合の生成文が入力制約を満たしつつ、意味的に妥当な日本語文として成立することが確認された。この結果は、日本語の音韻構造および大規模言語モデルの文脈推論能力が、欠落した子音情報の補完に寄与し得ることを示している。

一方で、制約遵守率（CCR）と BLEU や BERTScore といった評価指標との関係を見ると、制約を満たしていない生成文が必ずしも意味的に破綻しているとは限らないことも観測された。これは、音韻的制約と意味的妥当性が必ずしも同一の水準で成立するものではないことを示唆している。

このような結果は、単一の平均値指標のみでは VCCR タスクの挙動を十分に捉えきれない可能性を示しており、生成結果の分布そのものに着目した分析が必要となる。

7.2 評価指標分布から見た VCCR タスクの特性

第 6 章で示した分布分析は、VCCR タスクが持つ構造的特性を理解する上で重要な示唆を与えるものである。

まず、wiki-ja (test), XLSum, JSTS のいずれのデータセットにおいても、母音列制約を満たした生成文（CCR=1）に限定すると、BERTScore_F1 は高スコア側に集中する傾向が確認された。これは、母音列という限定的な音韻情報であっても、大規模言語モデルが文脈情報を活用することで、意味的に妥当な文生成を行えていることを示している。

一方で、BLEU_char の分布は、データセットによって大きく異なる挙動を示した。特に JSTS では、BERTScore_F1 が比較的高い生成文であっても、BLEU_char が低い値を取る例が多数観測された。これは、VCCR タスクが解の一意性を持たない不定問題であり、意味的に妥当な複数の表現が許容される状況では、参照文との表層一致に基づく評価が生成品質を十分に反映し

ない場合があることを示している。

このような分布の乖離は、VCCR タスクの失敗を意味するものではなく、むしろ本タスクの本質を反映した結果であると解釈できる。すなわち、母音列制約下では、「完全な復元」よりも「意味的に妥当な文候補を生成できるか」が重要であり、その評価には意味類似度指標を中心とした多角的な指標設計が不可欠である。

以上より、本研究の分布分析は、VCCR タスクにおいて BLEU を単独で用いることの限界と、BERTScore や制約遵守率（CCR）を併用する評価枠組みの妥当性を裏付けるものと位置付けられる。

次節では、これらの分布的特徴が実際の生成文においてどのような形で現れるのかを、具体的な成功例および失敗例を通じて検討する。

7.3 モデル構造の違いと生成能力の類似性

本研究では、Encoder-Decoder 型の T5 と、Decoder-only 型の GPT-2 という、設計思想の大きく異なる 2 種類の大規模言語モデルを用いて VCCR タスクを評価した。両モデルは入力扱い方や生成過程において本質的に異なる構造を持つにもかかわらず、定量評価および分布分析の結果からは、全体として同程度の生成能力を示すことが確認された。

この結果の第一の要因として、VCCR タスクにおける入力情報の極端な制約が挙げられる。母音列のみが与えられる条件下では、語彙的・統語的情報の大部分が失われており、モデル構造の違いを活かすための入力情報自体が限定されている。その結果、T5 による入力全体の明示的な符号化と、GPT-2 による逐次的な生成という違いが、性能差として顕在化しにくくなったと考えられる。

第二に、日本語が持つ音韻的および語彙的制約の強さが、探索空間を大きく制限している点が重要である。日本語では、モーラ構造や音韻配列論的制約により、母音列が与えられた時点で許容される語彙や表現の候補が大幅に絞り込まれる。このため、異なる生成経路を辿るモデルであっても、到達可能な「意味的に妥当な文」の集合が結果として類似したものになったと解釈できる。

第三に、両モデルが大規模な日本語テキストによる事前学習を通じて、日本語の語彙分布や文法構造、意味的共起関係を高い精度で獲得している点も無視できない。VCCR タスクでは、新たな推論能力よりも、既存の言語知識に基づいて「日本語として自然であり得る文」を選択する能力が支配的に働く。この観点では、T5 と GPT-2 はともに強力な言語モデルであり、事前学習によって獲得された言語分布が生成結果を強く規定したと考えられる。

さらに、VCCR タスク自体が理論的に解の一意性を持たない不定問題であることも、モデル間の性能差を縮小させる要因となっている。意味的に妥当な複数の表現が許容される状況では、参照文との完全一致を前提とする評価指標によってモデル間の微細な差異を捉えることが難しくなる。その結果、異なるモデル構造であっても、評価指標上は同程度の性能に収束したと考

えられる。

以上より、本研究において観測された T5 と GPT-2 の生成能力の類似性は、モデル設計の差異が無意味であることを示すものではなく、むしろ VCCR タスクにおいて支配的なのが言語構造と事前学習による言語分布であることを示唆している。この結果は、制約付き生成タスクにおけるモデル構造と問題設定の関係を考察する上で、重要な示唆を与えるものと位置付けられる。

7.4 VCCR タスクの限界

本論文で繰り返し述べてきたように本研究で扱った VCCR タスクは、理論的に解が一意に定まらない不定問題である。そのため、元文の完全な復元を目標とすることは適切ではなく、一定の曖昧性が不可避である。

また、本研究では母音列が正確に与えられることを前提としており、実際の VSR システムにおいて生じる母音認識誤りや時間的ずれについては考慮していない。したがって、本研究の結果は、理想化された条件下での上限性能を示すものと位置付けられる。

さらに、制約を事後的に評価する手法を採用したため、生成過程そのものにおいて制約がどのように扱われているかについては、直接的な制御や可視化を行っていない。この点は、本研究の設計上の制約である。

7.5 VSR 応用への示唆

以上の結果を踏まえると、VCCR タスクは、読唇システムにおける完全な音声復元を目的とするものではなく、限定的な音韻情報から意味的に妥当な文候補を生成する補助的モジュールとして位置付けることが適切である。

具体的には、VSR システムが母音列を高精度に抽出可能である場合、VCCR モデルを用いることで、複数の文候補を生成し、後段の意味理解や対話システムと組み合わせることが考えられる。このような構成により、視覚情報のみから得られる不完全な音韻情報を、言語モデルによって補完する可能性が示された。

7.6 本研究から得られた知見

本研究を通じて得られた主要な知見は以下の通りである。

- 母音列という極端に制約された音韻情報であっても、日本語の音韻構造と文脈推論能力を活用することで、一定水準の意味的妥当性を持つ文生成が可能である。
- VCCR タスクは解が一意に定まらない不定問題であり、完全一致を目標としない評価枠組みが不可欠である。
- 制約遵守と意味的妥当性は必ずしも一致せず、複数の評価指標を併用する必要性が確認

された.

第 8 章 結論と今後の展望

8.1 結論

本研究では、日本語を対象とした「母音列制約付き子音復元 (Vowel-Constrained Consonant Restoration; VCCR)」という新たな生成タスクを定義し、その実現可能性と限界を計算論的に検証した。

VCCR タスクは、入力として与えられる母音列に対して対応し得る日本語文が原理的に複数存在するという意味で、解が一意に定まらない不定問題である。本研究ではこの性質を前提とし、元文の完全な復元を目的とするのではなく、厳格な母音列制約を満たしつつ、意味的に妥当な文生成がどの程度可能であるかを評価対象として設定した。

実験の結果、母音列という極めて限定的な音韻情報のみが与えられた場合でも、日本語の音韻構造および事前学習済み大規模言語モデルの文脈推論能力を活用することで、一定割合の生成文が制約を満たしつつ意味的に妥当な日本語文として成立することが確認された。また、制約遵守率 (CCR) を導入し、既存の自動評価指標と併用することで、VCCR タスクにおける生成挙動を多角的に分析可能であることを示した。

これらの結果から、VCCR タスクは完全復元を目指す課題ではなく、読唇システムにおける補助的モジュールとして、限定的な音韻情報から意味的に妥当な文候補を生成するという点で一定の貢献可能性を持つことが示された。

8.2 今後の展望

本研究には、いくつかの今後の発展可能性が存在する。以下では、VCCR タスクの拡張および応用に向けた主な研究方向を整理する。

8.2.1 入力母音列の不確実性を考慮した拡張

第一に、入力母音列の不確実性を考慮した拡張が挙げられる。本研究では、母音（および撥音）列が正確に与えられることを前提としたが、実際の視覚的音声認識システムでは、母音認識誤りや時間的ずれが生じ得る。今後は、確率的な母音列表現や、複数候補の母音列を入力として扱う枠組みを導入することで、より現実的な条件下での検証が可能になると考えられる。

8.2.2 限定的な子音情報を取り入れた生成モデル

第二に、子音情報を限定的に取り入れた生成モデルの導入が考えられる。本研究では、視覚的に高精度で抽出可能な母音（および撥音）列のみに基づく文生成を対象としたが、実際の機械読唇環境においては、子音情報も完全に失われるわけではない。子音は母音と比較して視覚的に曖昧であるものの、唇閉鎖を伴う両唇音や一部の鼻音など、視覚的特徴が比較的顕著な子音については、一定の識別可能性が報告されている [40]。

このような限定的な子音情報を部分的な条件として利用できれば、生成され得る語彙候補の空間をさらに絞り込むことが可能となり、語彙選択や単語境界の決定精度の向上に寄与すると考えられる。母音列を主制約としつつ、信頼度の高い子音情報のみを補助的に統合する生成モデルを構築することは、VCCR タスクの拡張として有望な方向性の一つである。

8.2.3 前の文脈情報を活用した文生成

第三に、前の文脈情報を活用した生成手法の検討が挙げられる。本研究では、母音列から単一文を生成する設定に焦点を当てたが、実際の言語使用や読唇場面においては、文はしばしば連続した文脈の中で出現する。前の文脈情報は、同一の母音列に対して複数の解釈が成立する場合に、その曖昧性を解消する重要な手掛かりとなり得る。

例えば、前文の意味内容を条件として生成を行うことで、複数の候補文の中から、より適切な語彙や表現を選択することが可能になると考えられる。文脈情報を明示的に取り入れたモデルを導入することにより、より自然で一貫性のある文生成が実現され、実際の読唇応用における有用性も高まると期待される。

8.2.4 生成過程における制約の明示的導入

第四に、生成過程において制約を明示的に扱う手法の導入が考えられる。本研究では、制約を事後的に評価する設計を採用したが、生成途中で制約を考慮するデコード戦略や、制約付き生成に特化したモデル構造を用いることで、制約遵守と生成品質の関係を、より詳細に分析できる可能性がある。

8.2.5 VCCR タスクの VSR システムへの統合

第五に、VCCR タスクを、視覚的音声認識システム全体の一部として統合する検討が挙げられる。母音列抽出、文生成、意味理解を段階的に組み合わせることで、視覚情報のみから得られる不完全な音韻情報を、より効果的に活用するシステム設計につながると期待される。

本研究で提案した VCCR タスクおよび評価枠組みは、視覚的音声認識と自然言語処理の接点

における基礎的な検討として位置付けられる．今後、本研究の知見が、音韻的制約を考慮した言語生成研究や、視覚情報を用いた言語理解の発展に寄与することを期待する．

謝辞

本論文の執筆にあたり，様々なご指導，ご支援をして頂いた指導教員の酒井哲也教授に深く感謝いたします。また，貴重なご意見，ご提案を頂いた酒井研究室の同級生にもお礼申し上げます。

参考文献

- [1] Quentin Summerfield. Lipreading and audio-visual speech perception. *Philosophical Transactions of the Royal Society of London. Series B, Biological Sciences*, Vol. 335, No. 1273, pp. 71–78, 1992.
- [2] Yannis M. Assael, Brendan Shillingford, Shimon Whiteson, and Nando de Freitas. LipNet: End-to-end sentence-level lipreading. In *arXiv preprint*, 2016.
- [3] Joon Son Chung and Andrew Zisserman. Lip reading in the wild. In *Asian Conference on Computer Vision (ACCV) Workshops*, 2016.
- [4] Joon Son Chung, Andrew Senior, Oriol Vinyals, and Andrew Zisserman. Lip reading sentences in the wild. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.
- [5] Themis Stafylakis and Georgios Tzimiropoulos. Combining residual networks with LSTMs for lipreading. In *Proceedings of Interspeech 2017*, pp. 3652–3656, 2017.
- [6] Triantafyllos Afouras, Joon Son Chung, Andrew Senior, Oriol Vinyals, and Andrew Zisserman. Deep audio-visual speech recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol. 44, No. 12, pp. 8717–8727, 2018.
- [7] Changchong Sheng, Gangyao Kuang, Liang Bai, Chenping Hou, Yulan Guo, Xin Xu, Matti Pietikäinen, and Li Liu. Deep learning for visual speech analysis: A survey. *arXiv preprint arXiv:2205.10839*, 2024.
- [8] Benjamin T. Files, Bosco S. Tjan, Jintao Jiang, and Lynne E. Bernstein. Visual speech discrimination and identification of natural and synthetic consonant stimuli. *Frontiers in Psychology*, Vol. 6, p. 878, 2015.
- [9] Cletus G. Fisher. Confusions among visually perceived consonants. *Journal of Speech and Hearing Research*, Vol. 11, No. 4, pp. 796–804, 1968.
- [10] Helen L. Bear and Richard Harvey. Phoneme-to-viseme mappings: the good, the bad, and the ugly. *Speech Communication*, Vol. 95, pp. 40–67, 2017.
- [11] William H Sumby and Irwin Pollack. Visual contribution to speech intelligibility in noise. *The journal of the Acoustical Society of America*, Vol. 26, No. 2, pp. 212–215, 1954.
- [12] Harry McGurk and John MacDonald. Hearing lips and seeing voices. *Nature*, Vol. 264, No.

- 5588, pp. 746–748, 1976.
- [13] Joon Son Chung and Andrew Zisserman. Lip reading in the wild. In *Proceedings of the Asian Conference on Computer Vision (ACCV)*, pp. 87–103, 2016.
- [14] Joon Son Chung, Andrew Senior, Oriol Vinyals, and Andrew Zisserman. Lip reading sentences in the wild. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 6447–6456, 2017.
- [15] Pingchuan Ma, Stavros Petridis, and Maja Pantic. Visual speech recognition for multiple languages in the wild. *Nature Machine Intelligence*, Vol. 4, No. 11, pp. 930–939, 2022.
- [16] Bowen Shi, Wei-Ning Hsu, Kushal Lakhotia, and Abdelrahman Mohamed. Learning audio-visual speech representation by masked multimodal cluster prediction. In *International Conference on Learning Representations*, 2022.
- [17] Kaoru Sekiyama, Yoh’ichi Tohkura, and Michio Umeda. A few factors which affect the degree of incorporating lip-reading and hearing in audiovisual speech perception. In *Proceedings of the 4th International Conference on Spoken Language Processing (ICSLP)*, 1996.
- [18] Timothy J. Vance. *The Sounds of Japanese*. Cambridge University Press, 2008.
- [19] Natsuko Tsujimura. *An Introduction to Japanese Linguistics*. Wiley-Blackwell, 3rd. edition, 2013.
- [20] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, Vol. 21, No. 140, pp. 1–67, 2020.
- [21] Mike Lewis, Yinhan Liu, Naman Goyal, Marjan Ghazvininejad, Abdelrahman Mohamed, Omer Levy, Veselin Stoyanov, and Luke Zettlemoyer. Bart: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, pp. 7871–7880, 2020.
- [22] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*, pp. 4171–4186, 2019.
- [23] Chris Hokamp and Qun Liu. Lexically constrained decoding for sequence generation using grid beam search. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2017.
- [24] Matt Post and David Vilar. Fast lexically constrained decoding with dynamic beam allocation for neural machine translation. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*

- (*NAACL-HLT*), 2018.
- [25] Y. Gal. An hmm approach to vowel restoration in arabic and hebrew. *Computational Linguistics*, 2002.
 - [26] Nizar Habash and Owen Rambow. Arabic diacritization through full morphological tagging. In *Human Language Technologies 2007: The Conference of the North American Chapter of the Association for Computational Linguistics; Companion Volume, Short Papers*, pp. 53–56, Rochester, New York, April 2007. Association for Computational Linguistics.
 - [27] Imed Zitouni, Jeffrey Sorensen, and Ruhi Sarikaya. Maximum entropy based restoration of arabic diacritics. In *Proceedings of the 21st International Conference on Computational Linguistics and the 44th Annual Meeting of the Association for Computational Linguistics (COLING/ACL)*, pp. 577–584, 2006.
 - [28] Robbie Haertel, Peter McClanahan, and Eric K. Ringger. Automatic diacritization for low-resource languages. *Language Resources and Evaluation*, 2010.
 - [29] A. Neme and S. Paumier. Restoring arabic vowels through omission-tolerant dictionary lookup. *Natural Language Engineering*, 2019.
 - [30] 阿部聖志朗. 機械読唇を用いた母音認識および子音認識による発話語推定. 法政大学大学院紀要. 理工学研究科編, Vol. 63, pp. 1–4, 3 2022.
 - [31] Hanqing Zhang, Haolin Song, Shaoyu Li, Ming Zhou, and Dawei Song. A survey of controllable text generation using transformer-based pre-trained language models. *arXiv preprint*, 2022.
 - [32] Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. Language models are unsupervised multitask learners. *OpenAI*, 2019.
 - [33] Tianyu Zhao and Kei Sawada. rinna/japanese-gpt2-medium. <https://huggingface.co/rinna/japanese-gpt2-medium>.
 - [34] Kei Sawada, Tianyu Zhao, Makoto Shing, Kentaro Mitsui, Akio Kaga, Yukiya Hono, Toshiaki Wakatsuki, and Koh Mitsuda. Release of pre-trained models for the Japanese language. In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pp. 13898–13905, 5 2024.
 - [35] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
 - [36] Tahmid Hasan, Abhik Bhattacharjee, Md. Saiful Islam, Kazi Mubasshir, Yuan-Fang Li, Yong-Bin Kang, M. Sohel Rahman, and Rifat Shahriyar. XL-Sum: Large-scale multilingual abstractive summarization for 44 languages. In *Findings of the Association for Computational Linguistics: ACL-IJCNLP*, 2021.
 - [37] Kentaro Kurihara, Daisuke Kawahara, and Tomohide Shibata. JGLUE: Japanese general lan-

- guage understanding evaluation. In *Proceedings of the 13th Language Resources and Evaluation Conference (LREC)*, pp. 2957–2966, 2022.
- [38] Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. BLEU: a method for automatic evaluation of machine translation. In *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL)*, pp. 311–318, 2002.
- [39] Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi. BERTScore: Evaluating text generation with BERT. In *International Conference on Learning Representations (ICLR)*, 2020.
- [40] 宮崎剛, 中島豊四郎. 日本語発話時の特徴的口形のコード化と口形変化情報表示方法の提案. 電気学会論文誌C (電子・情報・システム部門誌), Vol. 129, No. 12, pp. 2108–2114, 2009.